Análise Comparativa de Classificadores - Lab2

João Armênio Silveira
Universidade Federal do Paraná

1. Introdução

Este relatório apresenta uma análise comparativa de seis classificadores clássicos de aprendizado de máquina: k-Nearest Neighbors (kNN), Naive Bayes (NB), Linear Discriminant Analysis (LDA), Logistic Regression (LR), Decision Trees (DT) e Support Vector Machines (SVM).

O estudo utiliza uma base de treinamento composta por 20.000 exemplos e uma base de teste com 58.646 instâncias, onde cada exemplo é descrito por 132 atributos. O objetivo é avaliar o desempenho, a eficiência temporal e a sensibilidade a hiperparâmetros sob diferentes disponibilidades de dados.

Todos experimentos foram feitos com os hiperparâmetros *default* do *scikit-learn* para os respectivos classificadores, o único definido manualmente foi $k = 5$ no kNN.

O código e os resultados do experimento podem ser encontrados no Github.

2. Desempenho em Função da Disponibilidade da Base

O SVM apresentou desempenho superior de forma consistente, atingindo 95,95% de acurácia com a base completa, seguido pelo kNN e LDA. Os modelos NB e DT apresentaram os menores índices. Observou-se que todos os algoritmos possuem capacidade de aprendizado conforme o volume de dados aumenta.

A curva de aprendizado (Figura 1) revela um crescimento acentuado entre 1.000 e 10.000 exemplos, intervalo onde a adição de dados gera ganhos substanciais. A partir de 10.000 exemplos as curvas tendem à estabilidade, indicando que o tamanho da base deixa de ser o fator limitante para o desempenho, resultando em ganhos apenas marginais.

A disparidade entre os modelos se mantém estável ao longo de toda expansão da base, reforçando a superioridade intrínseca de arquiteturas mais complexas como o SVM em relação às mais simples como o NB e LR.

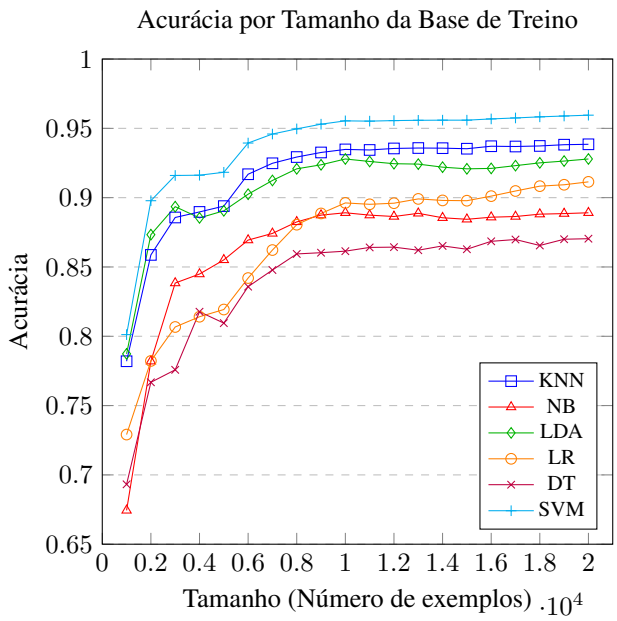

Figure 1. Comparação de Acurácia entre modelos por tamanho da base.

3. Desempenho com Poucos Dados

Em conjuntos menores de dados (inferior a 1.000 exemplos), o comportamento dos modelos se altera (Figura 2). Para volumes de extrema escassez (20 exemplos), o Naive Bayes destaca-se como o mais eficiente, iniciando com 52,91% de acurácia. Contudo, a partir de 100 exemplos, o SVM assume a liderança e a mantém em todo o restante do experimento. O kNN demonstrou um comportamento muito próximo ao SVM nesta escala, enquanto o LDA e LR tornam-se competitivos apenas ao aproximar-se da marca de 1.000 instâncias.

4. Mais Rápido para Classificar 58k Exemplos de Teste

Os modelos foram avaliados quanto ao tempo necessário para classificar os 58.646 exemplos de teste (Figura 3). LDA, LR e DT foram os mais rápidos, com tempo de 0,01s.

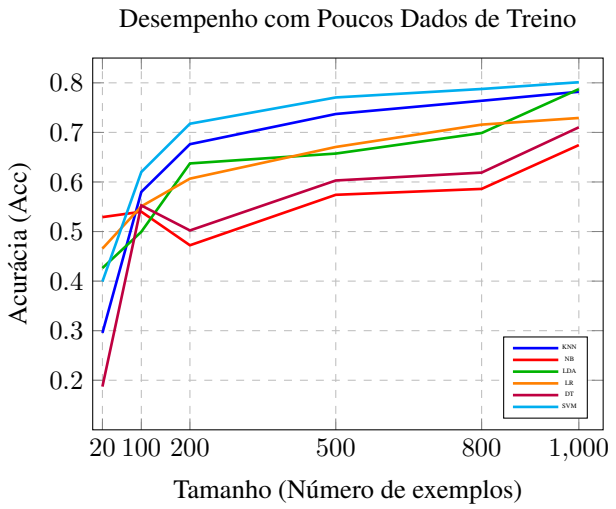

Figure 2. Acurácia dos modelos em função da disponibilidade da base (treino reduzido).

Em contraste, o SVM e o kNN exigiram custos computacionais significativamente maiores (15,70s e 1,23s, respectivamente).

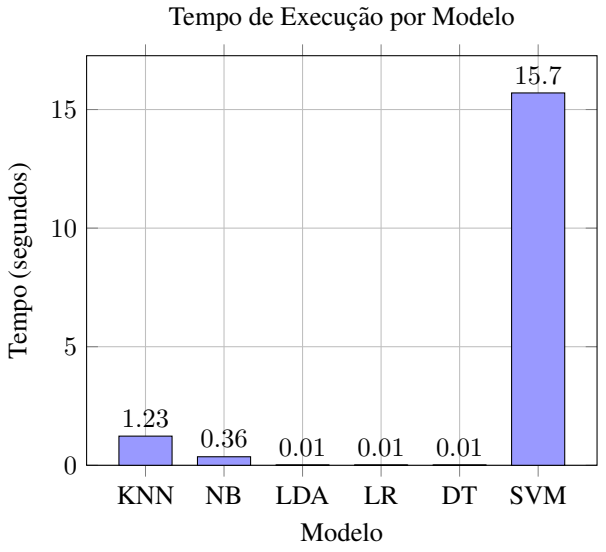

Figure 3. Comparativo de tempo usando todos exemplos.

Nota-se que o alto tempo do SVM deve-se ao uso do kernel RBF. Testes com kernel linear reduziram o tempo para 7,72s, que é significativamente menor, porém ainda maior que todos outros classificadores.

5. Impacto dos hiper-parâmetros nos resultados

A implementação de cada classificador possui diversos parâmetros que podem alterar de diferentes formas a execução do modelo. Aqui vou levar em conta apenas o parâmetros principais, mais ligados ao desempenho de cada modelo.

- **kNN:** Geralmente $k = 1$ sofre de over-fitting, porém nesse caso, este resultou na melhor acurácia obtida pelo kNN (94,02%). A acurácia decresce conforme k aumenta, sugerindo que as classes formam clusters pequenos e densos.
- **Decision Trees:** O parâmetro max_depth foi crucial. Profundidades baixas (2 ou 3) resultaram em underfitting, com 27% e 39% de acurácia respectivamente. A estabilização ocorreu a partir de profundidade 10, a partir desse ponto, o ganho na base de teste é pequeno. No teste $max_depth = None$, onde a acurácia de treino é 1.0 (over-fitting), a acurácia de teste atinge 86,89%.
- **SVM:** A transição do kernel linear (93,81%) para RBF (95,95%) e o ajuste de $C = 10$ indicam que a fronteira de decisão é não-linear e o modelo beneficia-se de uma margem menos flexível.
- **Modelos Lineares/Estatísticos (NB, LDA, LR):** Apresentaram alta resistência a variações de parâmetros, com impactos mínimos no desempenho final.

6. Análise das Matrizes de Confusão

De acordo com as matrizes de confusão (Figura 4), embora treinados no mesmo conjunto, os classificadores apresentam padrões de erro distintos. O SVM detém o menor erro absoluto e maior equilíbrio entre classes. NB e DT cometem mais erros absolutos, sendo os classificadores mais fracos.

Observou-se confusões persistentes entre a Classe 5 e a Classe 3 em quase todos os modelos (exceto NB), com destaque para o kNN e LR. A Classe 4 é frequentemente confundida com a Classe 9, sinalizando similaridade morfológica ou estatística entre estas categorias no espaço de características. A Classe 8 demonstrou ser a mais instável, com erros dispersos entre múltiplas classes em todos os modelos avaliados.

7. Conclusão

O SVM consolidou-se como o classificador mais robusto tanto para grandes volumes quanto para conjuntos moderados de dados, embora ao custo de um tempo de inferência significativamente maior. Para cenários de tempo real ou

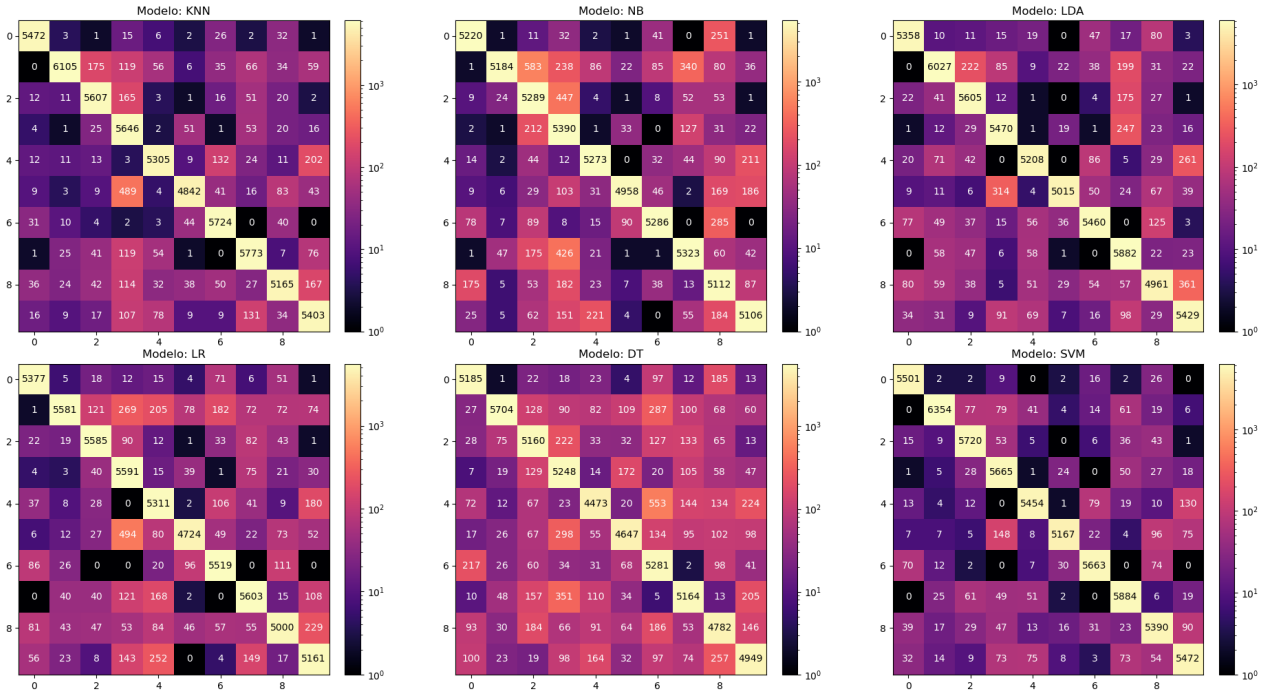

Figure 4. Matrizes de confusão dos modelos

recursos limitados, LDA e LR oferecem um equilíbrio ideal entre velocidade e precisão. Por fim, o Naive Bayes permanece a escolha mais segura para casos de extrema escassez de dados iniciais.